

实习生笔试题目

题目1

英伟达 GPU 处理器的存储系统，可以概括地分为片上内存（On-chip Memory）和片下内存（Off-chip Memory）。片上内存由静态随机存储器（SRAM, Static Random-Access Memory）实现，集成在 GPU 核心内部，访存速度极快，但造价高容量小。片下内存由动态随机存储器（DRAM, Dynamic Random-Access Memory）实现，处于 GPU 核心外部，访存速度低于片上内存但容量极大，也被称为全局内存。在目前的高性能 GPU 中，数据首先从显存（全局内存）传输到片上内存，然后再供计算单元使用。概括地，使用 GDRAM 代指片下内存，SRAM 代指片上内存。

在 GDRAM 中有两个张量 $Q \in \mathbb{R}^{N \times d}$ 和 $K \in \mathbb{R}^{n \times d}$ ，数据类型是 float16。假设处理器有 P 个执行单元，每个执行单元拥有私有片上内存 SRAM 为 M bytes。首先

$S = QK^T, S \in \mathbb{R}^{N \times n}$ ，然后对 S 在 n 维度排序并选出前 k 大的数据

$O = \text{topk}(S), O \in \mathbb{R}^{N \times k}$ 。写一个函数（伪代码）实现该计算过程，需考虑存储层次、并行计算、分块大小和排序稳定性等（伪代码中矩阵相乘可以使用函数 `gemm()`）。

题目2

在 AI 大模型中常通过注意力计算来捕获上下文相关性特征，常用的注意力计算公式（进行了简化，即单头注意力） $\text{AttnOut} = \text{softmax}(\frac{QK^T}{\sqrt{d}})V$ ，其中

$Q \in \mathbb{R}^{N \times d}, K \in \mathbb{R}^{N \times d}, V \in \mathbb{R}^{N \times d}, \text{AttnOut} \in \mathbb{R}^{N \times d}$ 。设定 $X = \frac{QK^T}{\sqrt{d}}, X \in \mathbb{R}^{N \times N}$ ，对于

$\forall x_{ij}, x_{ij} \in X, i \in [0, N-1], j \in [0, N-1]$ ，

$\text{softmax}(x_{ij}) = \frac{e^{x_{ij}-m_i}}{\sum_{j=0}^{N-1} e^{x_{ij}-m_i}}, m_i = \max_{j=0}^{N-1}(x_{ij})$ 。首先，写一个函数实现 AttnOut

计算过程（可以使用 `exp()` 函数）；其次，思考 $\text{softmax}()$ 如何并行计算，写一个函数（伪代码）并行计算 AttnOut 。

题目3

基于题目1中介绍的存储层次，假设处理器有 P 个执行单元，每个执行单元拥有私有片上内存（大小为 S bytes），执行单元每次最大可以执行

$A \cdot B = C, A \in \mathbb{R}^{m \times k}, B \in \mathbb{R}^{k \times n}, C \in \mathbb{R}^{m \times n}$ 矩阵运算（m, n, k 为给定常数）且私有片上内存足以存储 A, B 和 C 三个矩阵（即 $S > \text{sizeof}(A) + \text{sizeof}(B) + \text{sizeof}(C)$ ）。

片下内存 GDRAM 中存储了 $Q \in \mathbb{R}^{M \times K}, K \in \mathbb{R}^{N \times K}$ 两个矩阵，数据类型为 float16，写一个函数（伪代码）实现 $O = QK^T, O \in \mathbb{R}^{M \times N}$ 并将 O 写入 GDRAM。需要考虑存储层次、并行计算、分块大小等。

题目4

P 个独立进程共同使用同一份数据，数据的长度为L。要求每个进程使用其中的完全不重叠且混洗(shuffle=True)的 $\frac{L}{P}$ 个数据，如果 L 可以被 P 整除，则每个进程消费相同长度的数据，如果不整除则根据参数 drop_last 决定丢弃或者补-1。写一个函数完成该功能。

例子：

若 L = 10, P=4, drop_last=True, shuffle=False, 则P0 = [0, 4] P1 = [1, 5] P2 = [2, 6] P3 = [3, 7]

若 L = 10, P=4, drop_last=False, shuffle=False, 则P0 = [0, 4, 8] P1 = [1, 5, 9] P2 = [2, 6, -1] P3 = [3, 7, -1]